



ENG DE DADOS COM HADOOP E SPARK 4



1. Planejando e Configurando um Cluster Hadoop

2. Usando MapReduce em Grandes Volumes de Dados

3. Armazenamento de dados com HBase e Hive

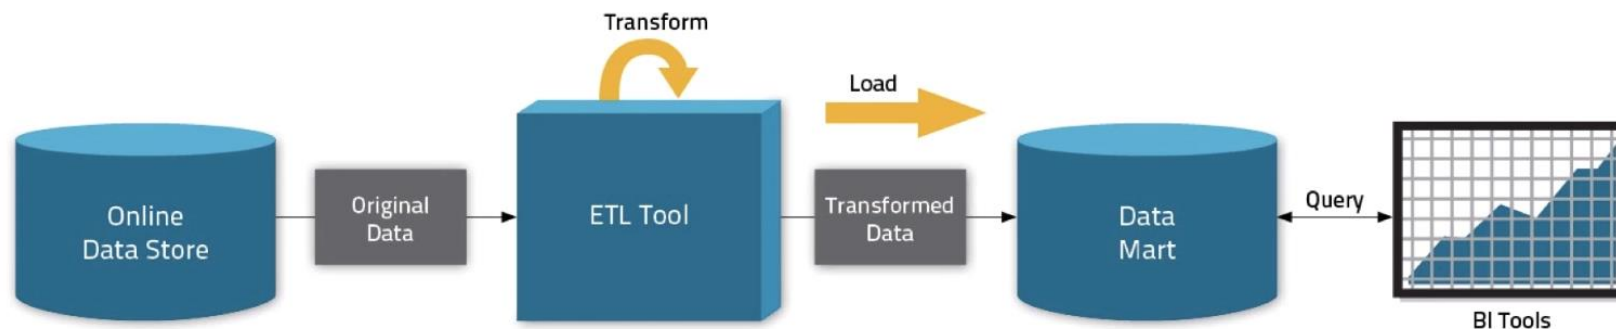
4. Conectividade ETL com o Sistema Hadoop

5. Administração e Manutenção do Hadoop

6. Hadoop Machine Learning com Apache Mahout

7. Apache Hadoop e Apache Spark

4. CONECTIVIDADE ETL COM O SISTEMA HADOOP




ETL = Extract – Transformation - Load

Logs e Streaming

Extra and Load

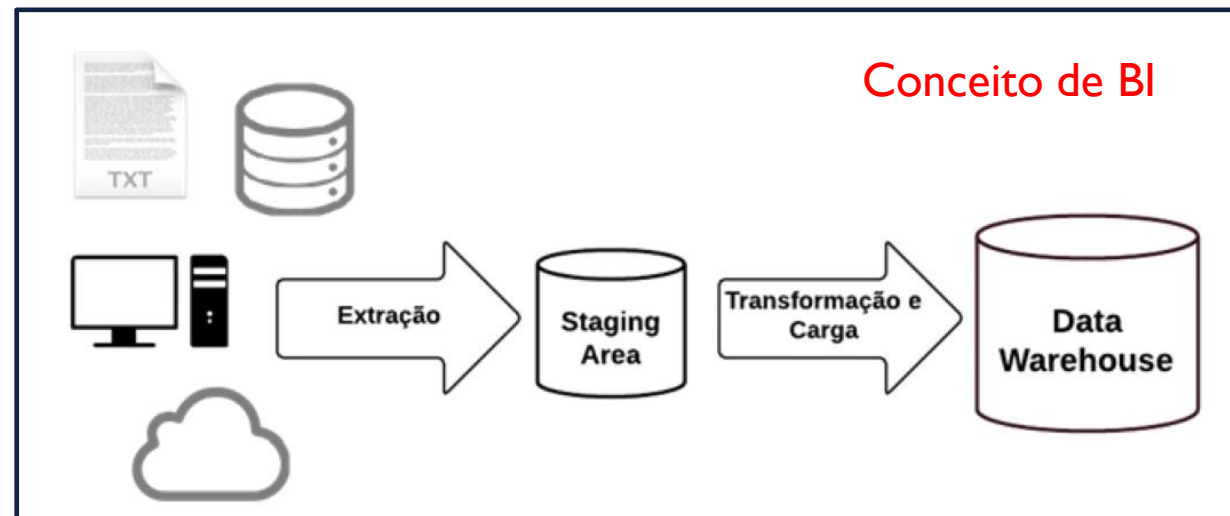
Batch



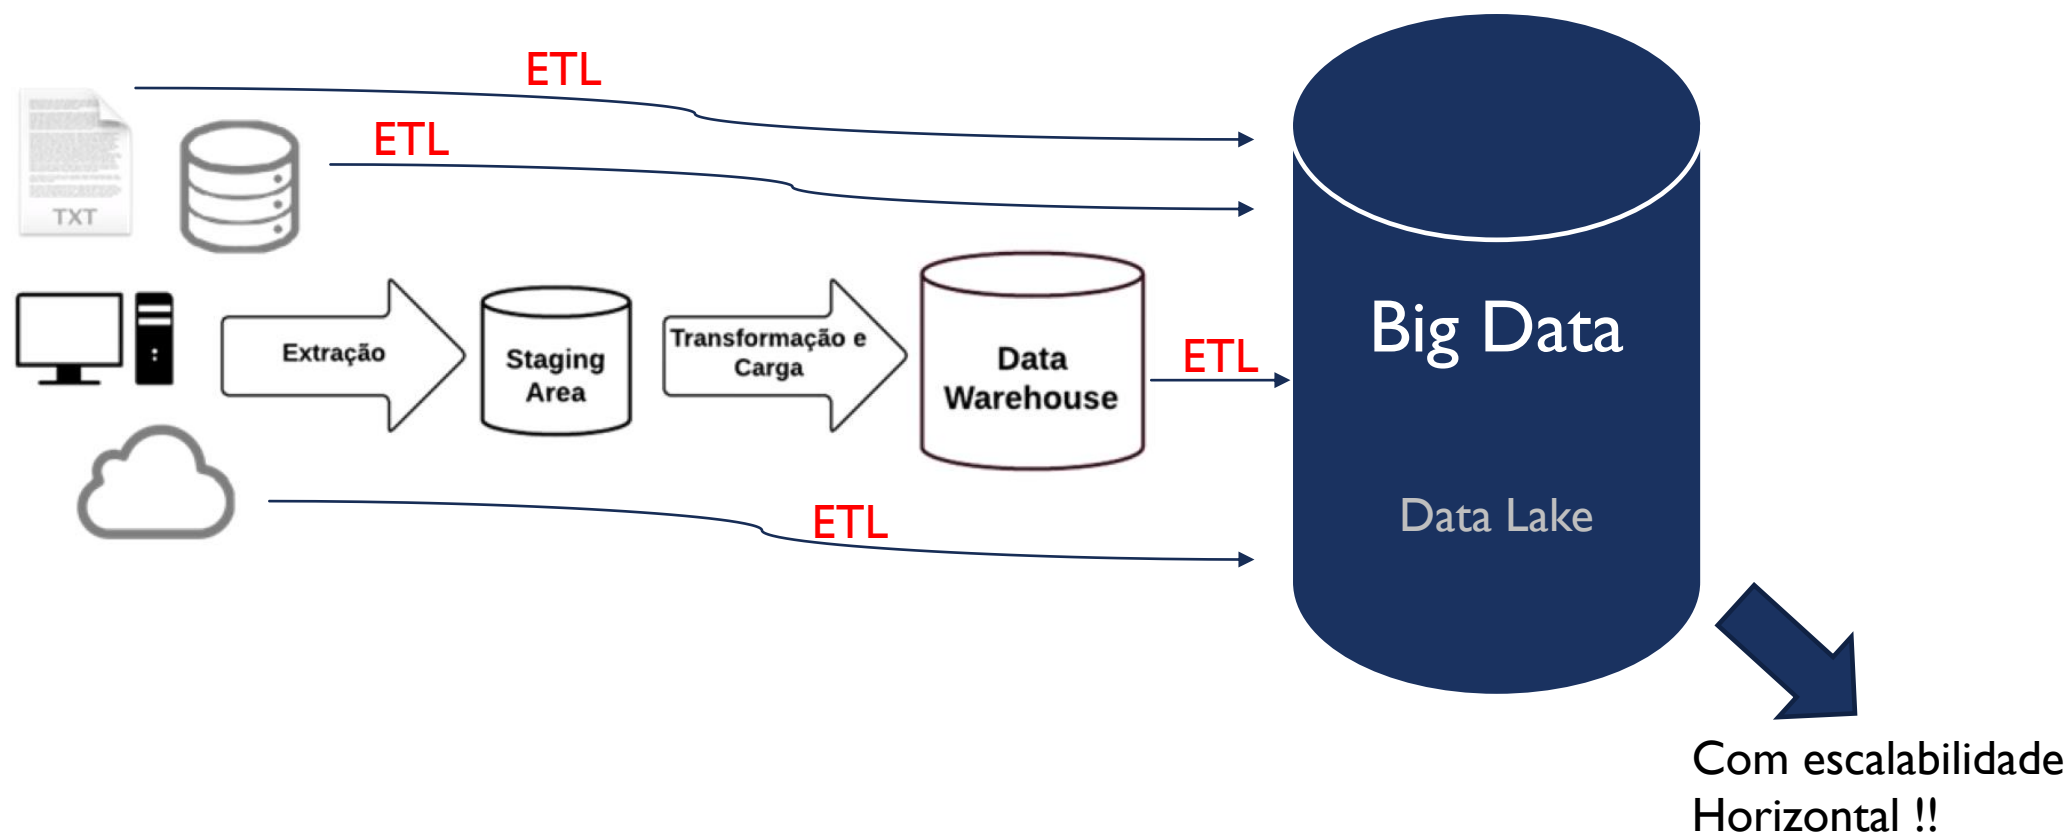
- Processo de ETL
- Principais ferramentas ETL do mercado
- Instalação de um ambiente com Banco de Dados Oracle
- ETL em ação

4.1 O QUE É ETL?

- ETL fornece a infraestrutura de integração através da realização de três importantes funções:



4.2 QUAL O PAPEL DO ETL NO BIG DATA?



4.3 PRINCIPAIS FERRAMENTAS ETL DO MERCADO

ETL é atribuição do Engenheiro de Dados!

Principais Ferramentas ETL - Proprietárias

- Informatica Power Center
- IBM InfoSphere Data Stage
- Oracle Data Integrator (ODI)
- Microsoft – SQL Server Integration Services (SSIS)
- SAS – Data Integration Studio
- SAP – Business Object Integrator
- Pentaho Data Integration

Principais Ferramentas ETL - Open Source

- Dataiku Data Science Studio (DSS) Community Edition
- Talend Open Studio For Data Integration
- Jaspersoft ETL
- Jedox
- RapidMiner
- Apache Flume
- Apache NiFi
- Apache Sqoop

ETL em tempo real!

Principal ferramenta ETL do ecossistema Hadoop para carga de dados em Batch (lote)

4.4 PRINCIPAIS BANCO DE DADOS DO MERCADO

364 systems in ranking, March 2021

Rank			DBMS	Database Model	Score		
Mar 2021	Feb 2021	Mar 2020			Mar 2021	Feb 2021	Mar 2020
1.	1.	1.	Oracle	Relational, Multi-model	1321.73	+5.06	-18.91
2.	2.	2.	MySQL	Relational, Multi-model	1254.83	+11.46	-4.90
3.	3.	3.	Microsoft SQL Server	Relational, Multi-model	1015.30	-7.63	-82.55
4.	4.	4.	PostgreSQL	Relational, Multi-model	549.29	-1.67	+35.37
5.	5.	5.	MongoDB	Document, Multi-model	462.39	+3.44	+24.78
6.	6.	6.	IBM Db2	Relational, Multi-model	156.01	-1.60	-6.55
7.	7.	8.	Redis	Key-value, Multi-model	154.15	+1.58	+6.57
8.	8.	7.	Elasticsearch	Search engine, Multi-model	152.34	+1.34	+3.17
9.	9.	10.	SQLite	Relational	122.64	-0.53	+0.69
10.	11.	9.	Microsoft Access	Relational	118.14	+3.97	-7.00
11.	10.	11.	Cassandra	Wide column	113.63	-0.99	-7.32
12.	12.	13.	MariaDB	Relational, Multi-model	94.45	+0.56	+6.10
13.	13.	12.	Splunk	Search engine	86.93	-1.61	-1.59
14.	14.	14.	Hive	Relational	76.04	+3.72	-9.34
15.	16.	15.	Teradata	Relational, Multi-model	71.43	+0.53	-6.41
16.	15.	23.	Microsoft Azure SQL Database	Relational, Multi-model	70.88	-0.41	+35.44

4.5 OPERAÇÃO DE ETL COM BANCO DE DADOS ORACLE E APACHE SQOOP

- O intuito desse projeto é montar um banco de dados relacional, simulando um data Warehouse com banco de dados Oracle para na sequência carregar 20 milhões de registros nesse banco de dados e então utilizar o Apache Sqoop como ferramenta ETL para levar os dados do Banco Oracle para o HDFS.





THANKS